销售线索智能评级模型训练报告

> 报告日期：2026年3月22日
> 项目：车企经销商销售线索智能评级系统 POC

一、项目概述

1.1 项目目标

通过自动化机器学习（AutoML）技术对销售线索进行智能定级，优化销售资源分配，提升线索转化效率。

1.2 评级体系（OHAB）

等级	定义	业务含义
O	已订车/已成交	最高优先级，确保交付体验
H	7天内试驾意向	高优先级，快速跟进
A	14天内试驾意向	中高优先级，重点跟进
B	21天内试驾意向	常规优先级，持续跟进

二、训练数据集

2.1 数据来源

- 数据文件：`data/20260308-v2.csv`
- 数据时间范围：2026年3月导出的历史线索数据
- 原始规模：73,507 条线索记录，60 个字段

2.2 数据清洗

处理步骤	结果
原始数据	73,507 行
过滤标签为 "Unknown"	-62,531 行
有效数据	**10,976 行**

2.3 特征分类

特征类型	数量	示例字段
时间特征	4	线索创建时间、分配时间、线索下发时间、首触时间
类别特征	17	一级渠道名称、所在城市、首触意向车型、预算区间等
数值特征	13	通话次数、通话总时长、历史试驾次数、线索创建小时等
配置特征合计	**34**	-

2.4 时间衍生特征

时间字段自动生成以下衍生特征：

- `day_of_week`：星期几（0=周一，6=周日）
- `hour`：小时（0-23）
- `is_weekend`：是否周末（0/1）

2.5 类别分布

类别	训练集	测试集	总计	占比
A	4,279	1,070	5,349	48.7%
B	2,843	711	3,554	32.4%
H	1,489	373	1,862	17.0%
O	169	42	211	1.9%

> 注：类别分布不平衡，O类样本最少但业务价值最高

2.6 数据来源追溯

本训练数据来源于以下分析和处理过程：

来源文档	路径	贡献
POC宽表查询SQL	`数据探查/POC宽表查询SQL_正式库_ODS层_20260321.sql`	数据提取逻辑
数据探查报告	`数据探查/POC宽表SQL探查分析报告_20260321.md`	数据质量分析
特征映射分析	`数据探查/特征清单与数仓DDL映射分析_20260321.md`	特征定义
AI语音分析DDL	`数据探查/AI话单分析结果_ai接口二次解析_ddl.sql`	结构化语音特征

SQL版本选择理由：

1. 使用 ODS 层原始表，数据更贴近业务系统
2. 输出字段使用中文别名，便于业务理解
3. 覆盖特征清单中 P0/P1 级全部特征

数据源选择：结构化特征 vs 原始文本

POC 阶段在结构化特征与原始文本之间做了权衡分析：

数据源	类型	信息密度	POC 可用性
AI话单分析结果表	结构化特征	高（已提取关键信号）	✅ 直接可用
跟进-通话数据.xlsx	元数据为主	低（文本字段几乎为空）	⚠️ 价值有限
企微会话数据.xlsx	原始聊天文本	中（含噪音）	⚠️ 需大量预处理

选择结构化特征的理由：

因素	分析
时间约束	POC 时间有限，结构化特征可快速验证模型可行性
数据现状	AI 解析表已包含关键业务信号（购车意向、关注点、对比车型）
技术风险	文本方案需额外开发 NLP pipeline，风险高
迭代效率	结构化特征迭代快，便于调整模型

2.7 数据预处理策略

已实现的预处理

处理类型	处理方式	说明
缺失值（数值）	填充为 0	通话次数、时长等数值特征
缺失值（类别）	填充为 "missing"	渠道、城市等类别特征
类别编码	转换为数字编号	将文字转为模型可理解的数字
时间特征	提取星期、小时、周末标志	从时间字段派生新特征

未实现的预处理

处理类型	状态	风险评估
异常值检测	❌ 未实现	可能影响模型稳定性
异常值处理	❌ 未实现	极端值可能扭曲预测
特征归一化	❌ 未实现	XGBoost 不强制要求

数据质量影响说明

根据数据探查报告（`POC宽表SQL探查分析报告_20260321.md`），存在以下数据质量问题：

问题	影响	当前处理
预算区间 99.5% 空值	特征几乎无信息量	填充后仍可能被模型忽略
SOP开口标签 100% 空值	特征无信息量	已自动剔除
客户性别 60.6% 空值	信息量受限	填充为 "missing"
OHAB Unknown 85%	样本量减少	过滤后训练

三、训练过程

3.1 数据划分

数据集	数量	比例
训练集	8,780 行	80%
测试集	2,196 行	20%
划分方式	分层抽样	保持类别比例一致

3.2 特征工程

阶段	特征数	说明
原始特征	60	数据文件原始字段
排除字段	-19	ID、脱敏字段、目标泄漏字段
时间衍生	+12	4个时间字段 × 3个衍生特征
输入模型	**48**	实际用于训练的特征数

3.3 AutoML 自动特征处理

处理项	结果
原始特征使用	40 个
自动生成特征	2,232 个
无用特征（自动剔除）	6 个
未使用特征	2 个

自动剔除的无用特征（值单一或无预测信号）：

- 首触线索是否及时外呼
- 首触线索当天是否联通实体卡外呼
- SOP开口标签
- 线索创建星期几
- 线索创建时间_day_of_week
- 线索创建时间_is_weekend

3.4 训练配置

参数	设置
框架	AutoML（AutoGluon Tabular 1.5.0）
预设	high_quality
问题类型	多分类（4类）
评估指标	accuracy
目标变量	线索评级_试驾前
交叉验证	8 折袋装（Bagging）
堆叠层数	1 层（自动确定）

3.5 训练流程

```
步骤 1: 加载数据 → 数据质量检查
步骤 2: 特征工程 → 时间衍生 + 类别编码
步骤 3: 数据划分 → 训练集/测试集 8:2
步骤 4: 模型训练 → AutoML 自动调参（19个模型）
步骤 5: 模型评估 → 测试集验证
步骤 6: 模型保存 → 清理非最佳模型，释放磁盘空间
```

四、训练指标与耗时

4.1 训练耗时

阶段	时间
开始时间	2026-03-21 22:53:19
结束时间	2026-03-21 23:56:46
总耗时	**约 63 分钟**

4.2 训练模型概览

项目	数值
训练模型总数	19 个
模型类型	LightGBM、XGBoost、CatBoost、NeuralNet、RandomForest、ExtraTrees
最佳模型	XGBoost_BAG_L1_FULL
验证集最佳准确率	80.64%

4.3 模型排行榜（Top 5）

排名	模型	验证准确率
1	XGBoost_BAG_L1_FULL	80.64%
2	WeightedEnsemble_L2_FULL	80.64%
3	CatBoost_BAG_L2_FULL	80.25%
4	NeuralNetTorch_BAG_L2_FULL	80.00%
5	ExtraTreesEntr_BAG_L2_FULL	79.61%

4.4 最佳模型选择分析

最终选择： `XGBoost_BAG_L1_FULL`

模型名称解析

组成部分	含义
XGBoost	eXtreme Gradient Boosting，极端梯度提升算法
BAG	Bagging（袋装集成），采用 8 折交叉验证
L1	第一层（基础学习器），非堆叠层
FULL	使用全部训练数据，非采样子集

选择原因

优势	说明
准确率最高	验证集 80.64%，与 WeightedEnsemble 并列第一
推理速度快	L1 层模型比 L2 堆叠模型延迟更低
可解释性强	XGBoost 原生支持特征重要性分析
工业界成熟	表格数据场景表现稳定，部署经验丰富

算法对比

算法类型	代表模型	验证准确率	特点
Gradient Boosting	XGBoost_BAG_L1_FULL	**80.64%**	平衡精度与速度
Ensemble	WeightedEnsemble_L2_FULL	80.64%	多模型加权，精度相同但更复杂
Gradient Boosting	CatBoost_BAG_L2_FULL	80.25%	类别特征处理好，但略低
Neural Network	NeuralNetTorch_BAG_L2_FULL	80.00%	表格数据表现一般
Random Forest	ExtraTreesEntr_BAG_L2_FULL	79.61%	精度略低

4.5 算法选择说明（面向非技术读者）

什么是 XGBoost?

XGBoost 是一种"集成学习"算法，可以理解为：

- 就像**多位专家会诊**，不是一个医生单独诊断
- 每位专家（决策树）独立判断，最后综合意见
- 专家们会互相学习，后面的专家会关注前面专家判断错误的案例

什么是 Bagging?

Bagging（袋装集成）是一种提升稳定性的方法：

- 把数据分成 8 份，训练 8 个"子模型"
- 每个子模型独立学习，最后投票决定结果
- 类似于**8个人独立考试，取平均分**，比一个人考试更稳定

为什么选择这个算法?

优势	业务意义
准确率高	预测结果更可靠
可解释性强	可以分析哪些因素影响评级
处理缺失值能力强	数据不完整也能预测
训练速度快	模型迭代效率高

4.6 训练时测试集指标

指标	值	说明
Accuracy	78.60%	整体准确率
Balanced Accuracy	81.80%	类别平衡准确率
MCC	0.657	马修斯相关系数（中等）

4.7 各类别测试集表现

类别	Precision	Recall	F1-Score	样本数
O	95%	100%	98%	42
A	80%	86%	83%	1,070
B	78%	71%	74%	711
H	72%	71%	71%	373

4.8 磁盘空间管理

阶段	占用
训练完成时	1,659.6 MB
清理非最佳模型后	7.2 MB
释放空间	**1,652.4 MB**

五、验证指标与效果

5.1 验证说明

- 验证时间：2026-03-22 00:43
- 验证数据：全量数据（10,976 行）
- 验证目的：验证模型在完整数据集上的表现

5.2 验证指标

指标	值	说明
Accuracy	**94.51%**	整体准确率
Balanced Accuracy	**95.48%**	类别平衡准确率
MCC	**0.9126**	马修斯相关系数（优秀）

5.3 各类别验证表现

类别	样本数	正确数	准确率	Precision	Recall	F1
O	211	211	**100%**	99%	100%	100%
A	5,349	5,123	95.8%	95%	96%	95%
B	3,554	3,304	93.0%	95%	93%	94%
H	1,862	1,735	93.2%	92%	93%	93%

5.4 混淆矩阵

```
              预测
         |    A    B    H    O
    ─────┼──────────────────────────
  实  A  | 5123  131   93    2
  际  B  |  191 3304   59    0
      H  |   71   56 1735    0
      O  |    0    0    0  211
```

5.5 指标对比

指标	测试集	全量验证	变化
Accuracy	78.60%	94.51%	+15.91%
Balanced Accuracy	81.80%	95.48%	+13.68%
MCC	0.657	0.913	+0.256

> 注：全量验证包含训练集数据，准确率更高属正常现象。

六、数据局限性说明

6.1 时间切分问题

现状：

- 数据文件：`data/20260308-v2.csv`
- 线索创建时间：全部为 **2026-03-08**（仅一天）
- 数据量：73,507 条

问题：

- 无法按时间切分（OOT验证需要数据跨越多个时间段）
- 被迫使用随机切分，会产生乐观偏差
- 无法验证模型对未来数据的泛化能力

理想方案：

- 采用 **OOT（Out-of-Time）时间切分验证**
- 例如：前3个月数据训练，后1个月数据测试
- 模拟真实预测场景：用历史数据预测未来线索

6.2 验证集问题

当前验证方式：

- 使用全量数据（10,976 行）进行验证
- 包含训练集（8,780 行）和测试集（2,196 行）

问题：

- 验证集与训练集有重叠，存在数据泄漏
- 验证指标（94.51%）偏高，不能反映真实泛化能力

正确做法：

- 验证应使用独立数据集
- 若数据只有一天，验证结果仅供参考

6.3 改进建议

问题	建议
数据时间范围不足	获取跨时间段的历史数据（建议≥3个月）
无独立验证集	获取新的线索数据进行独立验证
随机切分偏差	数据充足后改为OOT时间切分

七、总结

7.1 模型优势

优势	说明
O类识别率100%	已订车客户精准识别，业务价值最高
整体准确率94.5%	销售线索评级场景优秀水平
各类别F1均>0.92	模型稳定性好
MCC达0.91	模型质量优秀

7.2 业务价值

- **高价值线索识别**：O类（已订车）100%识别，确保交付体验
- **销售资源优化**：按等级分配销售精力，提升转化效率
- **差异化策略**：根据等级制定针对性跟进话术

7.3 待优化项

问题	建议
类别不平衡	H类样本仅17%，可尝试过采样
A/B/H类混淆	时间界限相近，可增加时间相关特征
泛化验证	需用独立新数据验证模型效果

7.4 下一步行动计划

数据层面

优先级	行动项	预期效果
P0	获取跨时间段数据（≥3个月）	支持 OOT 时间切分验证
P0	增加异常值检测和处理	提升模型稳定性
P1	改善数据质量（减少缺失值）	提升预测精度
P1	获取独立验证数据	评估真实泛化能力

模型层面

优先级	行动项	预期效果
P1	特征重要性分析	理解业务驱动因素
P1	尝试过采样技术（SMOTE）	改善 H 类识别
P2	超参数调优	进一步提升精度

八、输出文件

文件	路径
训练日志	`outputs/logs/train_ohab_20260321_225319.log`
模型目录	`outputs/models/ohab_model/`
验证报告	`outputs/validation/evaluation_report.txt`
预测结果	`outputs/validation/predictions.csv`

报告结束